

Plano de Modernização em Engenharia de Dados

O plano inicia com uma avaliação consultiva da estrutura atual, identificando limitações e requisitos para migração para AWS, culminando na construção de um data lake com Iceberg, orquestração via Airflow e camadas do medalhão. Ele abrange de abril a dezembro de 2026, dividido em fases bimestrais, com migração de bancos MySQL legados e novos (15GB cada) para Iceberg escalável de 30GB inicial a 100GB.

Estrutura Atual

Sistema legado CRM: monolítico com backend PHP, frontend HTML/CSS e RDS MySQL (15GB), sem separação de camadas, limitando escalabilidade e integração.

Novo sistema: backend Node.js, frontend Next.js e MySQL (15GB), já modular mas ainda sem data lake; fontes externas incluem outros CRMs e documentos locais, exigindo ingestão variada. Limitações comuns: dependência de MySQL para analytics, falta de streaming (Kafka) e transformações (dbt), sem data warehouse unificado.

Casos de uso iniciais por departamento usam gabarito: documentação (0), tabelas mais acessadas (1), com mais dados/sensíveis, views existentes/necessárias/refatoráveis/usadas; frequências de update para tabelas/CRM/dashs guiam pipes.

Arquitetura Proposta

Data lake em S3 com Glue Catalog/Iceberg para warehouse, Athena para queries; orquestração Airflow 3.1.8 em ECS Fargate cluster com EFS para storage dinâmico; Kafka containerizado para mensageria/streaming; dbt para transformações SQL.

Suporte: Route53 para domínios Airflow/Kafka; EC2/ALB/SG para proxies; migração MySQL → Iceberg via Glue jobs/pipes ETL; camadas medalhão (bronze raw, silver cleaned, gold marts por dept). Escalável para 100GB, integrando fontes externas.

Fases do Cronograma

Fase	Prazo	Entregas Principais	Dependências
1	Abr-Mai	Setup infra, PoC migração	AWS accounts
2	Jun-Jul	Bancos em Iceberg silver	Fase 1 ok
3	Ago-Set	Pipes Airflow/Kafka	Dados silver
4	Out-Nov	Gold marts, escalada	Pipes rodando
5	Dez	Finalização	Testes pass

Estimativa de Custos AWS

Estimativa mensal para stack (us-east-1, 100GB dados, workloads médios): ~\$664 USD. Custos iniciais baixos (setup), escalando com uso; otimize com Savings Plans/S3 tiering.

Service	Monthly Cost USD	Notes
ECS Fargate (Airflow + dbt + Kafka containers, 4 vCPU 8GB avg)	400.0	~4 tasks running 24/7 [web:18]
EFS (100GB Standard)	30.0	\$0.30/GB [web:12]
S3 Data Lake (100GB Standard)	2.3	\$0.023/GB [web:20]
Glue Catalog & Iceberg ops	10.0	Per DPU-hour est
Athena queries (est 10TB scanned/mo)	25.0	\$2.50/TB scanned [web:13]
EC2 (2x t3.medium for ALB/SG/proxy)	100.0	\$0.04/hr each
ALB	25.0	\$0.0225/hr + LCU [web:14]
Route53 (2 domains)	1.5	\$0.50/domain/mo
RDS MySQL legacy (temp)	50.0	db.t3.medium 15GBx2
Data transfer out (est)	20.0	1GB free, then \$0.09/GB